

Selenium

Bigdata
Selenium을 이용한 인스타그램 크롤링
2020. 6. 11. 17:32

<

Google 광고

의견 보내기

이 광고가 표시된 이유 ⓘ

안녕하세요 씨앤티 시스템즈의 김준형 입니다.

이번 포스트는 크롤링에 대해서 정리해 보았습니다.

그중에서도 BeautifulSoup 와 Selenium을 이용해서 인스타그램의 데이터를 받아와 보겠습니다.



셀레니움이란

Selenium은 웹사이트 테스트를 위한 도구로 브라우저 동작을 자동화할 수 있습니다. 프로그래밍으로 브라우저 동작을 제어해서 마치 사람이 이용하는 것 같이 웹페이지를 요청하고 응답을 받아올 수 있습니다. 예를들어 2페이지버튼이 단순 url이아니라 Javascript로 이루어져 있다면 시스템이 동작해서 화면전환이 이루어지기 때문에 크롤링할때 꼭 필요한 기술이라고 할 수 있습니다.

실행환경은 윈도우에서 진행하였습니다.

Python은 설치되어 있고 환경변수를 설정했다고 가정하고 진행하겠습니다.

인스타그램 크롤링은 Selenium과 Chrome을 연결해서 진행하기 때문에 Chrome 드라이버가 필요합니다.

(Chrome버전은 크롬 설정에서 -> Chrome 정보탭으로 가면 크롬 정보에서 확인할 수 있습니다.)

Chrome 정보



Chrome



Chrome이 최신 버전입니다.

버전 83.0.4103.97(공식 빌드) (64비트)

Chrome 도움말 보기



문제 신고



로그인

아래 Chrome 홈페이지에서 자신의 크롬버전에 해당하는 드라이버를 다운받아 주세요.

<https://chromedriver.chromium.org/downloads>

	Downloads - ChromeDriver - WebDriver f... WebDriver for Chrome chromedriver.chromium.org
--	---

이제 크롬 드라이버 옆에 적당한 이름의 .py 파일을 만들어주세요. (ex. insta.py)

그 후에 다음과 같이 필요한 프레임워크를 추가합니다.

```
from bs4 import BeautifulSoup
import selenium.webdriver as webdriver
import urllib.parse
from urllib.request import Request, urlopen
from time import sleep
import pandas as pd

import pandas_csv #검색 결과를 .csv파일로 만들기 위한 파이썬 파일
```

검색어를 사용자에게 받아오고 해당하는 인스타그램 게시물의 정보를 받아오기 위한 소스를 추가합니다.

```
search = input("검색어를 입력하세요 : ")
searching = str(search)
search = urllib.parse.quote(search)
url = 'https://www.instagram.com/explore/tags/'+str(search)+'/'
driver = webdriver.Chrome('chromedriver.exe')
```

```
driver.get(url) #검색어입력한 인스타그램 url 저장
sleep(3) #로딩 시간을 위한 속도조절
```

로그인

```
SCROLL_PAUSE_TIME = 1.2 #인스타그램 스�크롤 속도 조절 ( 1.0 ~ 2.0까지 상황에 맞게 조절 )
```

반복문을 통해 가져올 게시물의 개수와 URL 정보를 구합니다.

크롬에서 f12를 눌러 개발자 모드로 진입하여 인스타 검색화면의 소스를 보면 class가 "Nnq7C weEf m"로 해당하는 부분을 찾을 수 있습니다. 이렇게 페이지 하나씩 해당하는 부분을 찾아 데이터를 변수에 저장하고 불러내는 방식입니다.

해당 페이지의 정보를 찾은 후 스크롤을 통해 다음페이지로 넘어갑니다.

로그인

```
<section class="EoFFK ygqzn"></section>
<div class="Etakw">
  <ul class="XQxOT">
    <div role="button" class="ZyFrc">
      <li class="gelp9 ruo9f Ppövg" role="menuitem">
        <div class="Pyrgt">
          <div class="C7Iaf X7Jcj">
            <div class="RR-Hc TkzGu" role="button" tabindex="0"></div>
            <div class="C4vWK">
              <h2 class="6lAJh">
                <div class="
                  ItkAl
                    <div class="sqdOp YnK7d
                      _BAS5s ZIAjV" href="/_bas5s/_bas5s/a?_aa=50
                    </div>
                  </h2>
                  <span class=""></span>
                <div class=""
                  sqdOp
                    </div>
                </div>
              </div>
            </div>
          </li>
        </div>
        <li></li>
        <ul class="WrS08"></ul>
        <ul class="WrS08"></ul>
        <ul class="WrS08"></ul>
        <ul class="WrS08"></ul>
        <ul class="WrS08"></ul>
        <ul class="WrS08"></ul>
        <ul class="WrS08"></ul>
        <ul class="WrS08"></ul>
      </div>
    </div>
  </div>
```

```

hashtags2 = []

reallinknum = len(reallink)
print("총"+str(reallinknum)+"개의 데이터.")
try: # 반복문 시작 ( print 명령어로 원하는 문자열인지 하나씩 확인해보시길 바랍니다.
    for i in range(0,reallinknum):
        hashtags2.append([])
        req = 'https://www.instagram.com/p'+reallink[i]
        driver.get(req)
        webpage = driver.page_source
        soup = BeautifulSoup(webpage, "html.parser")
        #print(soup)
        soup1 = str(soup.find_all(attrs={'class': 'e1e1d'}))
        #print(soup1)
        user_id = soup1.split('href="/')[1].split('/')[0]
        #print(user_id)
        soup1 = str(soup.find_all(attrs={'class': 'Nm9Fw'}))
        #print(soup1)
        subValue = 'span'
        if(soup1==""): #좋아요가 0개, 1개, n개 일 경우 모두 소스가 다르다.
            likes = '0'
        elif( soup1.find(subValue)==-1):
            likes = soup1.split('좋아요 ')[1].split('개')[0]
        elif( soup1.find(subValue)!=-1):
            likes = soup1.split('<span>')[1].split('</span>')[0]

        soup1 = str(soup.find_all(attrs={'class': 'x1l3i'}))
        if(soup1==""): #해쉬태그가 없을 경우 소스가 다르다.
            hashtags = '해쉬태그없음'
            insert_data = { "search" : searching,
                            "user_id" : user_id,
                            "좋아요" : likes,
                            "hashtags" : hashtags}
            pandas_csv.to_csv(insert_data)
        else:
            soup2 = soup1.split(',')
            soup2num = len(soup2)
            for j in range(0,soup2num):
                hashtags = soup2[j].split('#')[1].split('</a>')[0]
                print(hashtags)
                insert_data = { "search" : searching,
                                "user_id" : user_id,
                                "좋아요" : likes,
                                "hashtags" : hashtags}
                #insert_data에 저장한 변수들 저장
                pandas_csv.to_csv(insert_data)

except:
    print("오류발생"+str(i+1)+"개의 데이터를 저장합니다.")

    pandas_csv.to_csv(insert_data) #insert_data에 저장한 데이터를 pandas_csv.py로 보냅니다.
    print("저장성공")

```

로그인

전체 소스입니다.

```

from bs4 import BeautifulSoup
import selenium.webdriver as webdriver
import urllib.parse
from urllib.request import Request, urlopen
from time import sleep
import pandas as pd

import pandas_csv #검색 결과를 .csv파일로 만들기 위한 파이썬 파일

search = input("검색어를 입력하세요 : ")
searching = str(search)
search = urllib.parse.quote(search)
url = 'https://www.instagram.com/explore/tags/'+str(search)+'/'
driver = webdriver.Chrome('chromedriver.exe')

driver.get(url) #검색어입력한 인스타그램 url 저장
sleep(3) #로딩 시간을 위한 속도조절

SCROLL_PAUSE_TIME = 1.2 #인스타그램 스크롤 속도 조절 ( 1.0 ~ 2.0까지 사양에 맞게 조절 )
reallink = []

while True: # 반복문 시작
    pageString = driver.page_source
    bs = BeautifulSoup(pageString, "lxml")

    # 게시물 정보
    for link1 in bs.find_all(name="div",attrs={"class":"Nnq7C weEfm"}):
        title = link1.select('a')[0]
        real = title.attrs['href']
        reallink.append(real)
        title = link1.select('a')[1]
        real = title.attrs['href']
        reallink.append(real)

    # 페이지 스크롤
    last_height = driver.execute_script("return document.body.scrollHeight")
    driver.execute_script("window.scrollTo(0, document.body.scrollHeight);")
    #sleep(SCROLL_PAUSE_TIME)
    new_height = driver.execute_script("return document.body.scrollHeight")
    if new_height == last_height:
        driver.execute_script("window.scrollTo(0, document.body.scrollHeight);")
        sleep(SCROLL_PAUSE_TIME)
        new_height = driver.execute_script("return document.body.scrollHeight")
        if new_height == last_height:
            break
    else:
        last_height = new_height
        continue

hashtags2 = []

reallinknum = len(reallink)
print("총"+str(reallinknum)+"개의 데이터.")
try: # 반복문 시작 ( print 명령어로 원하는 문자열인지 하나씩 확인해보시길 바랍니다.
    for i in range(0,reallinknum):
        hashtags2.append([])
        req = 'https://www.instagram.com/p'+reallink[i]
        driver.get(req)
        webpage = driver.page_source
        soup = BeautifulSoup(webpage, "html.parser")
        #print(soup)
        soup1 = str(soup.find_all(attrs={'class': 'e1e1d'}))
        #print(soup1)
        user_id = soup1.split('href="/')[1].split('>')[0]
        #print(user_id)
        soup1 = str(soup.find_all(attrs={'class': 'Nm9Fw'}))
        #print(soup1)
        subValue = 'span'
        if(soup1==""): #좋아요가 0개, 1개, n개 일경우 모두 소스가 다르다.
            likes = '0'
        elif( soup1.find(subValue)==-1):
            likes = soup1.split('좋아요 ')[1].split('개')[0]
        elif( soup1.find(subValue)!=-1):
            likes = soup1.split('<span>')[1].split('</span>')[0]

```

로그인



```

soup1 = str(soup.find_all(attrs={'class': 'xil3i'}))
if(soup1==""): #해쉬태그가 없을 경우 소스가 다르다.
    hashtags = '해쉬태그없음'
    insert_data = { "search" : searching,
                    "user_id" : user_id,
                    "좋아요" : likes,
                    "hashtags" : hashtags}
    pandas_csv.to_csv(insert_data)
else:
    soup2 = soup1.split(',')
    soup2num = len(soup2)
    for j in range(0,soup2num):
        hashtags = soup2[j].split('#')[1].split('</a>')[0]
        print(hashtags)
        insert_data = { "search" : searching,
                        "user_id" : user_id,
                        "좋아요" : likes,
                        "hashtags" : hashtags}
        #insert_data에 저장한 변수들 저장
        pandas_csv.to_csv(insert_data)

except:
    print("오류발생"+str(i+1)+"개의 데이터를 저장합니다.")

    pandas_csv.to_csv(insert_data) #insert_data에 저장한 데이터를 pandas_csv.py로 보냅니다.
print("저장성공")

```

수집 데이터를 CSV파일로 저장하기위한 pandas_csv.py 파일입니다.

```

import os
import pandas as pd
from datetime import datetime, timedelta
import configparser
import glob

config = configparser.ConfigParser()
#설정파일이 있는경우 설정합니다.
#config.read('/root/crawling/crawler.conf')

def to_csv(data):

    pathlink = "./"

    # db create
    if not os.path.isdir(pathlink):
        os.mkdir(pathlink)

    present_date = str(datetime.utcnow() + timedelta(hours=9))[:10] #파일명에 날짜구분하기 위한 시간

    # col = ["search", "user_id", "좋아요", "hashtags"]

    # CSV파일 생성
    if len(glob.glob(pathlink + "/" + present_date + ".csv")) == 1:
        cnt = len(pd.read_csv(pathlink + "/" + present_date + ".csv", index_col=0).index)
        time_pd = pd.DataFrame(data, index=[cnt])
        time_pd.to_csv(pathlink + "/" + present_date + ".csv", mode='a', header=False, encoding='utf-8-sig')
    else:
        cnt = 0
        time_pd = pd.DataFrame(data, index=[cnt])
        time_pd.to_csv(pathlink + "/" + present_date + ".csv", mode='a', encoding='utf-8-sig')

```

--실행화면

-- 수집 명령어 실행 및 로그확인

```

PS C:\Users\CNT\Desktop\크롤링> python3 .\winstarnotmul_cnt.py
검색어를 입력하세요 : 베니

DevTools listening on ws://127.0.0.1:1949/devtools/browser/60f8551c-24b2-406f-867d-cc211417793d
[20612:22788:0611/151417.820:ERROR:device_event_log_impl.cc(208)] [15:14:17.821] Bluetooth: blue
총260개의 데이터.
benee
supaloney
귀염뽀짝
베니
benny
베니_성장앨범
베니
benny
베니_성장앨범
베니
benny
베니_성장앨범
반려견
멍멍이
멍멍이그림
멍스타그림
개스타그림
개엄마
일상
주말
강아지
강아지그림
토이푸들
푸들
가을
데일리
점중마
주부
홈스타그램

```

-- Chrome 페이지가 시작되고 수집을 시작합니다.

-- .py폴더 안에 .csv파일을 확인할 수 있습니다.

A	B	C	D	E
	search	user_id	좋아요	hashtags
0	베니		1,685	benee
1	베니		1,685	supaloney
2	베니		1,685	귀염뽀짝
3	베니		1,412	베니
4	베니		1,412	benny
5	베니		1,412	베니_성장앨범
6	베니		1,634	베니
7	베니		1,634	benny
8	베니		1,634	베니_성장앨범
9	베니		1,478	베니
10	베니		1,478	benny
11	베니		1,478	베니_성장앨범
12	베니		1,478	반려견
13	베니		1,478	멍멍이
14	베니		1,478	멍멍이그림
15	베니		1,478	멍스타그림
16	베니		1,478	개스타그림
17	베니		1,478	개엄마
18	베니		1,478	일상
19	베니		1,478	주말
20	베니		1,478	강아지
21	베니		1,478	강아지그림
22	베니		1,478	토이푸들
23	베니		1,478	푸들
24	베니		1,478	가을
25	베니		1,478	데일리
26	베니		1,478	점중마
27	베니		1,478	주부
28	베니		1,478	홈스타그램

로그인

지금은 CSV파일로 저장하고 끝나지만 다음 시간에는 Elasticsearch나 RDB로 바로 저장되는 자동화 부분을 배워보도록 하겠습니다.

웹데이터 -> .CSV -> Elasticsearch,RDB

이렇게 데이터가 저장되어 축적되면 빅데이터 관련해서 많은 부분에 사용될 수 있다고 생각합니다.

'Bigdata' 카테고리의 다른 글

- Google Cloud Platform의 BigQuery 소개 →
- 하둡 완전본산 환경 설치 및 설정 (hadoop cluster setup) →
- Spark을 이용한 Deeplearning →
- Spark SQL(Pyspark) →
- Spark DataFrame (PySpark) →

beautifulsoup # Crawling # DataLake # Python Crawling # selenium # 빅데이터 # 인스타그램
인스타그램 크롤링 # 크롤링 # 파이썬

이름 암호



Lightfidelity
2020.08.29 15:24

로그인



에러가 발생되어 ...! 이렇게 무례하게 여쭙습니다. 혹시나 자문을 ...!
C:\Anaconda3\envs\python_instagram\python.exe C:/Users/HP/pythonProject/crawl_inst.py
검색할 태그를 입력하세요 ## : car
Traceback (most recent call last):
File "C:/Users/HP/pythonProject/crawl_inst.py", line 39, in <module>
bs = BeautifulSoup(pageString, "lxml")
File "C:\Anaconda3\envs\python_instagram\lib\site-packages\bs4__init__.py", line 242, in __init__
raise FeatureNotFound(
bs4.FeatureNotFound: Couldn't find a tree builder with the features you requested: lxml. Do you need t
o install a parser library?

Process finished with exit code 1

수정/삭제 댓글쓰기 신고



Lightfidelity
2020.08.29 15:34

IndexError: list index out of range

During handling of the above exception, another exception occurred:

"lxml" install 하고 나니...! 성공 한듯 한데
Traceback (most recent call last):
File "C:/Users/HP/pythonProject/crawl_inst.py", line 115, in <module>
pandas_csv.to_csv(insert_data)
NameError: name 'insert_data' is not defined

Process finished with exit code 1

수정/삭제 신고



 씨앤티

2020.09.14 10:02

답변이 늦어져서 죄송합니다 ㅠㅠ

소스 내에서 insert_data를 못찾는 것 같습니다. 혹시나 선언한 이름과 호출하는 이름을 다르게 적으신건 아니신지요??

전체 소스 코드 복사하셔서 붙여넣고 실행 한번 해보시는게 좋을 것 같습니다.

아니면 저는 실행할 때 python3로 실행하는데 이게 관련이 있을지도 모르겠습니다

수정/삭제 신고